SYSTEM DESIGN • RAG • LLM ENGINEERING

Методы, алгоритмы и архитектура ИИ-решений

Андрей Носов

AI Architect

Детерминизм в стохастических системах

ГАЙДЛАЙН

"Temperature=0 и Seed не гарантируют 100% идентичность на уровне байтов из-за нелинейности вычислений на GPU, но фиксируют логику."

Float Point Errors

Альтернативные подходы

Greedy Decoding

Полное отключение случайности. Выбор наиболее вероятного токена на каждом шаге.

Min-P Sampling

Новая альтернатива Top-P. Лучше отсекает «мусорные» токены, не ограничивая творческий потенциал модели в кодинге.

Logprobs

Анализ вероятности каждого токена для оценки «уверенности» модели в написанном коде.

Chain of Thought - расширение стэка вызовов

ГАЙДЛАЙН

"CoT — это не просто «думай пошагово», а способ заставить модель использовать скрытые состояния (scratchpad)."

Scratchpad Mechanism

Что пробовать ещё

System Prompt vs User Prompt

Жёсткое разделение ролей. Инструкции по безопасности и стилю — только в System.

Few-Shot via XML/Markdown

Использование чётких разделителей для примеров кода (<example>...</example>) работает на 30% лучше для моделей 3B-8B.

Output Formatting

Принуждение к JSON/Pydantic через response_format на уровне API вместо промпта.

Chunking — «Слабое звено» любого RAG

ГАЙДЛАЙН

"В ноутбуке мы используем RecursiveCharacterTextSplitter. Для Senior-задач этого мало."

Standard Approaches

Продвинутые подходы

Small-to-Big Retrieval

Ищем по маленьким чанкам (предложениям), а в модель отдаем большой контекст (весь абзац или функцию).

Parent Document Retrieval

Храним иерархию (Заголовок → Метод → Код).

Contextual Chunking

Добавление краткого описания всего файла в начало каждого чанка, чтобы чанк «знал», к какому классу он относится.

Эмбеддинги и векторные пространства

ГАЙДЛАЙН

"all-MiniLM-L6-v2 — это «затычка» для тестов. Не используйте её как основное решение для сложных задач."

Baseline only

Выбор в Production

Matryoshka Embeddings

Модели, позволяющие обрезать длину вектора без потери точности, что критично для экономии памяти в векторных БД.

Late Interaction (ColBERT)

Хранение векторов для каждого токена вместо одного на документ. Дорого по ресурсам, но точность поиска по коду выше в разы.

Fine-tuned Embeddings

Дообучение модели эмбеддингов на вашей специфичной кодовой базе и проприетарных библиотеках для максимальной релевантности.

Архитектура векторного хранилища

ГАЙДЛАЙН

"ChromaDB хороша для ноутбука. Для хайлоада смотрим на другие параметры."

Performance Scaling

Альтернативы для Production

Qdrant / Milvus
Поддержка фильтрации по метаданным на уровне движка (Payload filtering).

PgVector
Если данные уже в Postgres — не плодите сущности, используйте расширение.

DiskANN
Алгоритм для поиска по миллиардам векторов на обычном SSD.

Hybrid Search — Зачем это реально нужно?

ГАЙДЛАЙН

"Векторный поиск (Dense) часто мажет на именах функций (getUserData vs fetchUser)."

Точность поиска по коду

Что тюнить

RRF (Reciprocal Rank Fusion)

Как настраивать веса. Обычно **0.7** для Вектора и **0.3** для Ключевых слов — золотой стандарт для кода.

BM25 Tuning

Настройка параметров `k1` и `b` для очень коротких документов (сниппетов кода).

Re-ranking: максимизация точности

ГАЙДЛАЙН

"Первый поиск (Retriever) должен быть быстрым и возвращать Топ-50. Второй этап — Re-ranker — должен быть точным и выбрать Топ-5."

ЭТАП 1	ЭТАП 2
Retriever	**Re-ranker**
Скорость (Топ-50)	Точность (Топ-5)

Что пробовать

Cross-Encoders (BGE-Reranker)

Подаём (Вопрос + Чанк) целиком в модель. Это в 10 раз точнее обычного косинусного сходства векторов.

Cohere Rerank API

Если допустимы облака — стандарт индустрии. Обеспечивает высокое качество ранжирования без необходимости хостить тяжелые модели.

Обработка запроса

ГАЙДЛАЙН

"Пользователи пишут плохие запросы. Нам нужно их переписать перед поиском."

Query Transformation

Техники оптимизации

HyDE (Hypothetical Document Embeddings)

Просим ИИ написать «гипотетический ответ» на вопрос, и ищем в БД по этому ответу, а не по вопросу.

Multi-Query Retrieval

Генерируем 3–5 вариаций вопроса, ищем по всем, объединяем результаты.

Query Decomposition

Разбиваем сложный технический вопрос на несколько простых под-вопросов.

Резюме и рекомендации

SUMMARY • KEY TAKEAWAYS

1. **Мало данных + общие вопросы?**
   → Simple RAG + Local LLM

2. **Специфичный синтаксис + поиск по ID/Ошибкам?**
   → Hybrid Search (BM25 обязателен)

3. **Критическая точность?**
   → Reranker + CoT Prompting

4. **Сложные зависимости в коде?**
   → Small-to-Big Retrieval + Metadata Filtering

ГЛАВНЫЙ СОВЕТ

"Не оптимизируйте LLM (промпты), пока не оптимизировали Retrieval (поиск)."

Если в контекст попал мусор — никакая «умная» модель не выдаст чистый код.

SYSTEM DESIGN

Методы, алгоритмы и архитектура ИИ-решений

ГАЙДЛАЙН

"Переход от «вызова API» к проектированию вычислительных графов. Архитектор должен понимать ограничения трансформерной архитектуры."

АЛГОРИТМИЧЕСКИЕ ОГРАНИЧЕНИЯ

Attention Bottleneck

Квадратичная зависимость от длины контекста. Длинные промпты замедляют TTFT.

FlashAttention-2, KV-Caching

MoE (Mixture of Experts)

Работают только нужные «эксперты». Качество 70B модели при затратах как на 10B.

АРХИТЕКТУРНЫЕ ПАТТЕРНЫ

Router Pattern

Легкая модель (3B) классифицирует запрос: RAG, тяжелая модель (70B) или SQL/API.

Semantic Cache

Хранение пар «Вопрос–Ответ». Similarity > 0.95 → отдаем кэш без вызова LLM.

Экономия денег/времени

SCALING & OPTIMIZATION

Speculative Decoding

Маленькая модель предсказывает токены, большая валидирует. Ускорение 2–3x.

Quantization Strategy

Выбор между FP16, INT8, GGUF Q4_K_M. Баланс Perplexity (точность) vs Throughput.

БИБЛИОГРАФИЯ И РЕСУРСЫ

Источники, репозитории и SOTA-исследования

"Список первоисточников для глубокого погружения в инженерную часть. Фундамент для построения надёжных RAG-систем."

SEMINAL PAPERS (ФУНДАМЕНТ)

Attention Is All You Need (2017)
Базовая архитектура трансформеров.

Retrieval-Augmented Generation (2020)
Основы RAG для Knowledge-Intensive NLP.

Precise Zero-Shot Dense Retrieval (HyDE)
Улучшение поиска через гипотетические ответы.

FRAMEWORKS & ECOSYSTEM

LangChain / LangGraph
Лучший ресурс по паттернам агентской логики.

LlamaIndex (High-level RAG)
Глубокие гайды по индексации сложных структур.

Model Context Protocol (MCP)
Спецификация Anthropic для инструментов ИИ.

BENCHMARKING & EVALUATION

Hugging Face Open LLM Leaderboard
Сравнение моделей «в голом виде».

LiveCodeBench
Оценка моделей в задачах программирования.

RAGAS (ragas.io)
Метрики оценки качества поиска (Faithfulness).

HARDWARE & SERVING

vLLM GitHub
PagedAttention для высоконагруженных систем.

Ollama Blog
Квантование и локальный запуск моделей.